

ENFOQUES Y CONSTRUCCIONES DE LA INVESTIGACIÓN EDUCATIVA EN ESTUDIOS DE POSGRADO

Coordinadores

María Verónica Nava Avilés, Antonio Medina Rivilla, Enrico Bocciolesi



HIU | Humanitas
Innovation University™



CAPÍTULO 6.

RELACIONES CAUSALES ENTRE VARIABLES

CARLOS ROMERO

PARA INICIAR LA investigación sobre un fenómeno, se requiere «recortarlo» de su ambiente —individuarlo— y tener al menos una hipótesis sobre qué factores podrían estar impactando en su ocurrencia o en las magnitudes que lo componen. En el caso más básico, representamos a esos factores como variables; de forma que la representación de ese fenómeno es como una *función* de esas otras variables. Este es probablemente el concepto más general de un modelo matemático.

Ahora bien, una de las relaciones más importantes que pueden existir entre dos variables es una relación *causal*. Este tipo de relaciones se dan cuando la ocurrencia de ciertos sucesos *produce, genera* o hace que otro suceso exista o *se modifique* de ciertas formas. Rastrear las relaciones causales en una red de fenómenos nos permite comprender cómo surgen y en dónde se puede intervenir en ellos, o incluso manipularlos para nuestros propósitos.

Pero la causalidad a veces se confunde con la *correlación*, que es la mera aparición conjunta de dos fenómenos. En esta contribución vamos a realizar un breve estudio de los conceptos de causalidad y correlación. El objetivo principal es comprender más profundamente la tesis de que *la correlación no implica a la causalidad*, al comprender los conceptos componentes. Para ello, es necesario tener un entendimiento, al menos elemental, de la teoría matemática de la probabilidad. Vamos a dedicar la siguiente sección (§1) para ello, mencionando algunos factores filosóficos en su interpretación. Este tratamiento del tema es, por necesidad, breve, además de casi puramente cualitativo; un tratamiento más extenso requiere de un libro entero. Sin embargo, espero que esto sea suficiente para tocar el tema de la rela-

ción entre causación y correlación, importante para la selección de variables. Después de ello, en la sección 2, analizaremos los conceptos de correlación y causalidad, así como la tesis de que la correlación entre dos variables no implica una relación causal entre ellas.

Probabilidad

La definición de la probabilidad

Por principio de cuentas, tenemos a la teoría matemática de la *medida*. Una medida es, simplemente, una manera de expresar con un número qué tan «grande» o «pequeño» es un conjunto de cosas.¹ Por ejemplo, el área de una figura o la altura de una persona pueden ser descritas por medidas, porque una figura y el área que contiene son conjuntos de puntos, y podemos representar a una persona como un conjunto de partes. Sus áreas y alturas son medidas de qué tan grandes son esos conjuntos de puntos o de partes.

Ahora bien, la teoría de la probabilidad es una teoría sobre una medida que nos dice qué tan grande es la probabilidad de que suceda un conjunto de eventos posibles. Y en el caso en que el conjunto solamente contiene a un evento, decimos que mide la probabilidad *del evento*. Así, la probabilidad de un conjunto de eventos mide el «grado de posibilidad» de que ocurran esos eventos.

Vamos a usar los símbolos « $\Pr(X)$ » como nombre del número que representa la probabilidad, dada por la medida $\Pr$, de un conjunto X ². Esta probabilidad se define como una medida particular que cumple estas reglas, conocidas como «Axiomas de Kolmogorov»:

1. *La probabilidad de todo conjunto de eventos es un número real entre 0 y 1 (inclusivo)*. Esto significa que todo evento tiene, o bien una probabilidad 0 de suceder —que sería un evento nada probable—, o bien una probabilidad 1 —que sería un evento *máximamente* probable—,

¹ Ver Rincón 2014

² Matemáticamente hablando, $\Pr$ —como todas las medidas— es una función. También notemos que X no puede ser cualquier conjunto: estrictamente hablando, tiene que pertenecer a lo que se conoce como una σ -álgebra.

o bien una probabilidad intermedia: un evento con 0.3 de probabilidad tiene menor probabilidad de ocurrir que uno con 0.6 de probabilidad, por ejemplo. Específicamente, un evento con 0.5 de probabilidad es completamente aleatorio, como lanzar una moneda al aire. En lenguaje matemático: $0 \leq \Pr(X) \leq 1$, para todo conjunto X al que se aplique la medida.

2. *La probabilidad de que ocurra alguno de todos los eventos posibles es 1.* Es decir: es seguro que ocurra algo: podemos no saber cuál, pero de todas las posibilidades, una tiene que ocurrir. En lenguaje matemático: $\Pr(U) = 1$, donde U es el conjunto de todos los eventos posibles, también llamado el «universo».
3. *La probabilidad de la alternativa entre eventos independientes* (es decir, que no se implican entre sí) es la suma de las probabilidades de cada uno de esos eventos. En lenguaje matemático:

$$\Pr(E_1 \text{ o bien, } E_2, \dots) = \Pr(E_1) + \Pr(E_2) + \dots$$

De manera equivalente, la probabilidad de que sucedan conjuntamente eventos independientes es el producto de sus probabilidades:

$$\Pr(E_1 \text{ y también, } E_2, \dots) = \Pr(E_1) \times \Pr(E_2) \times \dots$$

Las reglas de Kolmogorov definen matemáticamente a la probabilidad y por ello, solamente nos dan eso: una teoría de las matemáticas puras, una teoría que nos habla de una *medida*. A su vez, interpretamos esa medida como la medida de algo: el grado de probabilidad de que ocurra un evento. Aquí todavía cabría preguntarnos qué es tal grado de probabilidad. ¿No es un estado misterioso, como un fantasma entre el ser y el no ser? ¿Si algo es meramente probable, existe o no existe? Además, la probabilidad no es solamente una rama de las matemáticas puras, también se aplica en la modelación de fenómenos concretos. Cuando esto sucede, es válido preguntarse qué representa la función matemática de probabilidad (y otras funciones asociadas, como una función de densidad de probabilidad). Este es el problema de la *interpretación de la probabilidad*.

Por las restricciones de enfoque y espacio, no podemos dedicar muchas palabras a este problema. Sin embargo, sí es importante distinguir, de manera muy general, entre dos concepciones de la probabilidad. Estas dos con-

cepciones no son necesariamente contradictorias, aunque en algunas áreas se ofrecen como interpretaciones contrarias. Veamos.

Me refiero a dos grandes formas de entender a la probabilidad de un evento: como una medida de su *oportunidad de ocurrir*, y como una medida de *nuestra ignorancia sobre las condiciones en las que ocurre*. Podemos clasificar a estas dos grandes formas como interpretaciones *objetivistas* y *epistémicas*.

Las interpretaciones objetivistas toman a la probabilidad como una propiedad de los eventos en sí mismos, independientemente de lo que nosotros pensemos o sepamos sobre ellos. La idea es que un evento que tenga una probabilidad objetiva va a tener cierta característica: cierta oportunidad de ocurrir, o cierto parecido con otros eventos que ya han ocurrido. Por otro lado, las interpretaciones epistémicas toman a la probabilidad «de» un evento como, en realidad, una medida de la ignorancia que tenemos sobre la ocurrencia o no de ese evento. Consideremos el caso en que lanzo una moneda al aire, un «volado». Las leyes de la física determinan la trayectoria en el espacio de esta moneda, partiendo de sus posición inicial, su masa, la fuerza con la que la lancé, la resistencia del aire, etcétera. Con ello, las leyes de la física determinan qué lado de la moneda va caer hacia arriba. Pero le asignamos 50 % de probabilidad a que caiga «sol» y 50 % a que caiga «águila» porque no sabemos cuál de las dos caerá: no tenemos un cálculo perfecto de la trayectoria de la moneda, pero sabemos que solamente puede caer una de las dos caras (dando por sentado que no caerá de canto), y que no hay razón alguna para suponer que sea más probable que caiga de un lado o del otro. Entonces, esa asignación de probabilidad es una expresión de lo que ignoramos, restringido por lo que sabemos. Habiendo aclarado las dos grandes concepciones de la probabilidad, revisemos algunos conceptos técnicos.

Variables

El primero es el concepto de *variable*. Esta es la representación matemática de una característica que posee algún sistema concreto. Como su nombre lo dice, una variable varía, pues da distintos valores al aplicarse a diferentes sistemas. Por ejemplo, supongamos que tengo la variable que representa a la *nacionalidad*. Cuando se usa para representarme, tomará el valor: *mexicano*.

Aplicada a Barack Obama, tomará el valor: *norteamericano*. Ahora bien, podemos distinguir diferentes tipos de variables por la *estructura* que suponen:

- **Cualitativas nominales.** Son las variables que representan propiedades que no tienen valores numéricos ni ordenamiento entre sí (como el estado civil o el lugar de nacimiento).
- **Ordinales.** Son las variables que representan cualidades que pueden ordenarse de menor a mayor o viceversa, pero que no necesariamente tienen un valor numérico (como la medalla ganada en una competencia o la preferencia entre un conjunto de productos).
- **Cuantitativas.** Son las variables que representan magnitudes, es decir, propiedades concretas a las que se les puede asignar un valor numérico (como el peso de un objeto o su velocidad). Entre estas, podemos distinguir dos subtipos:
- **Discretas.** Son las variables que toman valores en conjuntos denumerables de números, como los naturales. Tienen pares de posibles valores que no tienen un valor entre ellos, de forma que uno es el sucesor del otro.
- **Continuas.** Son las variables que toman valores en los números reales, variando continuamente: entre cada dos posibles valores siempre habrá un tercero, sin «huecos» entre ellos.

Las variables ordinales pueden ser cualitativas, como las medallas en una competencia, donde primero iría el oro, luego la plata y finalmente el bronce. A veces se expone el tema como si todas las variables ordinales fueran cualitativas, pero estrictamente hablando, esto es incorrecto. Toda variable cuantitativa (continua o discreta) también es ordinal, porque los números siempre pueden ordenarse de mayor a menor.

Por otro lado, para los propósitos de modelar un fenómeno, es esencial comprender cuáles son sus relaciones con otras variables. Para este fin, tenemos esta otra clasificación de las variables:

- **Independientes.** Son aquellas cuyos valores no dependen de la influencia de otra variable dentro del modelo. Son factores *exógenos* o *externos* a los fenómenos modelados, de forma que sus valores son «suposiciones» desde el punto de vista del modelo, no implicaciones de este.

- **Dependientes.** Son aquellas cuyos valores son una función de las variables independientes: *dependen* de ellas. El objetivo de un modelo es representar al fenómeno estudiado de forma que nos permita entender cómo es que las variables independientes influyen —causalmente— en las variables dependientes.
- **Intervinientes.** Como dice su nombre, son aquellas que afectan las influencias de las variables independientes sobre las dependientes.

Así, un modelo consiste en la descripción de la relación causal de las variables independientes sobre las dependientes, que puede estar mediada por las variables intervinientes.

Variables aleatorias

Uno de los conceptos fundamentales de la estadística es el de *variable aleatoria*. Esta se define por tres características que ahora voy a explicar.

En primera, una variable aleatoria representa cuantitativamente una característica de nuestro objeto de estudio, por lo que tomará valores numéricos. Por ejemplo, quizá nos interese estudiar a los planetas del sistema solar; en ese caso, podríamos usar variables que representen la masa de cada planeta.

La segunda característica definitoria de una variable aleatoria es que *depende de circunstancias aleatorias*, es decir, puede tomar valores distintos en distintas circunstancias, donde estas circunstancias son generadas por un proceso aleatorio. Por ejemplo, al lanzar una moneda al aire, tenemos un proceso aleatorio, que produce una circunstancia aleatoria: que la moneda caiga «águila» o que caiga «sol». Así, podríamos tener una variable aleatoria, X , que tome cierto valor dependiendo de cuál sea el resultado de lanzar la moneda. Como las variables aleatorias deben ser numéricas, basta con asignarle un «1» a la cara con águila, y un «0» a la cara con sol. Entonces, dependiendo del resultado del lanzamiento, la variable describe a la moneda como $X = 1$ o $X = 0$.

La tercera característica es que los valores que toma una variable aleatoria en cada circunstancia posible tienen cierta probabilidad. Regresando al caso de la moneda, la probabilidad de que $X = 1$ —de que la moneda caiga en águila— es $1/2$, igual que la probabilidad de que $X = 0$, pues la moneda

solamente tiene dos caras. Pero ahora consideremos el caso en el que lanzamos un dado que no está cargado. Definimos una variable aleatoria, Y , que tomará un valor de 1 a 6, dependiendo de qué cara del dado caiga. Como suponemos que el dado no está cargado, cada cara tiene la misma probabilidad de caer. Además, las probabilidades deben sumar 1. Entonces, como son seis caras (y suponemos que debe caer solamente una), sus probabilidades deben sumar 1 y tienen la misma probabilidad, cada cara tiene una probabilidad de $1/6$ de caer. Así, tenemos que la probabilidad de que $Y = 1$ es de $1/6$, igual que la probabilidad de que $Y = 2$, $Y = 3$, etc.

Formalmente hablando, una variable aleatoria va a ser una función que tome eventos y nos regrese números³. En este texto vamos a ocuparnos de manera prácticamente exclusiva de variables discretas; aunque algunos conceptos fundamentales son muy similares para las variables continuas.

Valor esperado o Esperanza

Antes vimos que una variable aleatoria va a tomar un valor en cada circunstancia posible con una probabilidad correspondiente. El valor esperado de una variable nos da algo parecido a un promedio de los valores que puede tomar, «controlado» por las probabilidades de que tome esos valores. Es, entonces, una media ponderada. Por ello, al valor esperado de una variable también se le conoce como su *media*, y cuando es claro de qué variable hablamos, simplemente escribimos « μ » para referirnos a su valor esperado. Pasemos a la definición del concepto.⁴

Valor esperado Sea X una variable aleatoria cuyos posibles valores son $x_1, x_2, \dots, x_n$, donde cada uno de estos puede ocurrir con una probabilidad, respectivamente, de $p_1, p_2, \dots, p_n$. El valor esperado de X , que denotamos con « $E[X]$ » o con « μ », se define así:

$$E[X] = x_1(p_1) + x_2(p_2) + \dots + x_n(p_n) = \mu(1)$$

³ Más formalmente hablando, es una función medible desde el espacio muestral de un espacio de probabilidad a un espacio medible, pero aquí no vamos a utilizar la definición rigurosa.

⁴ Vamos a considerar el caso más elemental, cuando la variable aleatoria tiene un espectro discreto y finito.

Es decir, es la suma de cada posible valor, multiplicado por la probabilidad de que la variable tome ese valor.

Así, entre más probable sea uno de sus valores, más peso tendrá al calcular ese promedio. Por las mismas razones, el valor esperado de una variable aleatoria incluso podría no ser uno de los valores que pueda tomar.

Un ejemplo de lo anterior es un dado justo (que no está cargado). Si lanzamos el dado, saldrá uno de los valores entre 1 y 6; cada uno de estos valores tiene la misma probabilidad de aparecer. Como son seis posibles valores, tenemos una probabilidad de $1/6$ para cada uno de ellos. Si calculamos el valor esperado de la variable aleatoria, X , que representa el número que sale tras lanzar el dado, obtenemos:

$$\begin{aligned}\mu &= \frac{1}{6} \cdot 1 + \frac{1}{6} \cdot 2 + \frac{1}{6} \cdot 3 + \frac{1}{6} \cdot 4 + \frac{1}{6} \cdot 5 + \frac{1}{6} \cdot 6 \\ &= \frac{1}{6} + \frac{2}{6} + \frac{3}{6} + \frac{4}{6} + \frac{5}{6} + \frac{6}{6} \\ &= \frac{21}{6} \\ &= 3.5\end{aligned}$$

Que no es uno de los valores que podrían resultar tras lanzar el dado. De nuevo, el valor esperado de la variable no siempre es uno de los valores que podría tomar, pero representa un promedio de los valores a los que tiende a largo plazo, considerando también a las probabilidades que tiene cada valor.

Desviación estándar

El valor esperado es una *medida de tendencia central*, pues nos dice a qué valores tiende en promedio la variable. También tenemos medidas de dispersión para las variables aleatorias, que nos dicen qué tan dispersos están los valores de esa variable *con relación al valor esperado*, al valor «promedio». La más importante de ellas es la *desviación estándar*.

Con poca desviación estándar, la mayoría de los posibles valores de la variable están cerca del valor esperado. Con mucha desviación estándar, hay muchos valores que podría tomar la variable lejanos a su valor esperado.

Vamos a definir la desviación estándar de una variable aleatoria X , que se suele escribir así: « σ_X », o sin el subíndice en caso de que se entienda de qué variable estamos hablando.

Desviación estándar. Sea X una variable aleatoria y $E[X]$ su valor esperado. Entonces, la desviación estándar de X se define así:

$$\sigma_X = \sqrt{E[(X - E[X])^2]}, \quad (2)$$

lo cual, por las propiedades del valor esperado, también implica:

$$\sigma_X = \sqrt{E[X^2] - (E[X])^2} \quad (3)$$

Si nos enfocamos en variables discretas X que solamente puedan tomar un número finito de valores x_i , cada uno con su respectiva probabilidad p_i , la ecuación 3 implica la siguiente fórmula para el valor esperado de X .

$$\sigma_X = \sqrt{p_1(x_1 - E[X])^2 + p_2(x_2 - E[X])^2 + \dots + p_n(x_n - E[X])^2} \quad (4)$$

Como el valor esperado es la media de la variable y también se denota por μ , la ecuación 4 puede reescribirse así:

$$\sigma_X = \sqrt{p_1(x_1 - \mu)^2 + p_2(x_2 - \mu)^2 + \dots + p_n(x_n - \mu)^2} \quad (5)$$

Esta es la definición más usual para calcular el valor esperado.

Vemos que la desviación estándar de X resulta ser la raíz cuadrada de la suma de: la distancia cuadrada entre cada posible valor y la media, multiplicada por su probabilidad. Es decir, es un tipo de promedio que nos dice qué tan lejos está cada valor de la media, controlando con la probabilidad de ese

valor. Si la variable puede tomar valores muy distintos, con probabilidades bastante parecidas, su desviación estándar va a ser muy alta. En cambio, si solamente puede tomar valores muy parecidos entre sí, con probabilidades parecidas, su desviación estándar va a ser baja. Ahora bien, si toma valores parecidos entre sí con probabilidades muy distintas, pero donde hay un sesgo en las probabilidades hacia cierto espectro de su valor, su desviación estándar va a ser también baja, pues los valores tienden más a acercarse a una magnitud, con poca probabilidad de alejarse de ella.

Una ventaja de la desviación estándar es que viene en las mismas dimensiones que la variable aleatoria. Para ilustrar esta ventaja, supongamos algún juego imaginario de un casino, donde algún proceso aleatorio produce cuatro posibilidades. Las cuatro tienen la misma oportunidad de suceder, por lo que la probabilidad de cada una es de $1/4 = 0.25$. En cada una de las cuatro posibilidades, ganamos o perdemos fichas del juego. Vamos a usar a la variable X para representar esto. Tenemos que, por las reglas del juego, estas son las pérdidas o ganancias:

- *Posibilidad 1:* ganamos 2 fichas. ($X = +2$, $\text{Pr} = 0.25$)
- *Posibilidad 2:* perdemos 2 fichas. ($X = -2$, $\text{Pr} = 0.25$)
- *Posibilidad 3:* ganamos 4 fichas. ($X = +4$, $\text{Pr} = 0.25$)
- *Posibilidad 4:* no perdemos ni ganamos ninguna ficha. ($X = +0$, $\text{Pr} = 0.25$)

En este juego, las probabilidades nos favorecen, pues si hacemos el cálculo, vemos que la media de X es 1 ficha: $E[X] = 1 = \mu$. Es decir, si jugamos muchas veces este juego, la tendencia a largo plazo es siempre ganar una ficha. (Sería un pésimo juego para un casino si no cobran más de una ficha para jugarlo, ¡pues estarían seguros de que no ganarán a largo plazo!) La desviación estándar es de ≈ 2.2 fichas, de forma que, en promedio, uno va a estar ganando o perdiendo dentro de un margen de dos fichas respecto a la media.

Correlación y causalidad

Como hemos dicho, el objetivo principal de esta contribución es analizar los conceptos de correlación y causalidad, de forma que podamos entender su

relación, que es algo esencial en la selección de variables para modelar un fenómeno.

Conceptos básicos

Empezamos definiendo algunos conceptos que serán útiles para comprender la relación entre causalidad y correlación.

- **Evento.** Un evento o suceso consiste en que un objeto particular tenga una propiedad en un momento y lugar determinado. (Por ejemplo, cuando José está feliz en la mañana del día de su cumpleaños, eso es un evento.) Cualquier suceso que ocurra, lo sepamos o no, nos parezca importante o no, o sea la que sea la reacción que nos provoque, es un evento en este sentido.
- **Causalidad.** Es la relación entre una serie o pluralidad de eventos en la que una parte —la causa o las causas— *provoca o genera o produce o hace que suceda* la otra parte —el efecto o los efectos. (Por ejemplo, la ciencia y la medicina clínica han comprobado que *fumar causa cáncer*. Para una persona específica, esto significa que toda la serie de eventos en los que ha fumado, provocaron, generaron o produjeron el evento del cáncer iniciándose en su sistema respiratorio, o eventos que llevarán a ese evento.)
- **Hipótesis causal.** Una proposición que afirma que un evento (o serie de ellos) es causado por otro evento (o serie de ellos). Como proposiciones que son, las hipótesis causales pueden ser objeto de creencias por parte de sujetos, o de afirmaciones de ellos; también pueden tener relaciones con la evidencia, o carecer de ellas.
- **Correlación.** La relación probabilística entre dos tipos de sucesos que nos indica si suelen suceder conjuntamente. La definición más usual de la correlación es el *coeficiente de correlación de Pearson*.⁵

Con los conceptos básicos sobre la mesa, vamos a definir el coeficiente de correlación de Pearson.

⁵ El coeficiente de Pearson no cubre todos los casos, pues solamente considera a la correlación *lineal*.

El coeficiente de Pearson

El coeficiente de Pearson es la forma más aceptada de medir la correlación lineal entre dos variables aleatorias. Se define mediante en términos de dos magnitudes: la covarianza y la desviación estándar. Arriba (§1.3.2) ya revisamos el concepto de desviación estándar, ahora hablemos sobre la covarianza.

La covarianza también es una forma de medir la relación entre dos variables aleatorias, de forma que una covarianza positiva entre ellas nos dice que a más altos valores de una, más altos valores de la otra también, y a más bajos valores de una, más bajos valores de la otra también. A su vez, una covarianza negativa nos dice que hay una relación inversa entre las variables: a más altos valores de una, más bajos los valores de otra, y viceversa. Si la covarianza es cero, no hay una relación (lineal) entre los valores que podrían tomar las variables aleatorias.

Veamos la definición de la covarianza entre dos variables aleatorias X , Y , que escribimos como «Cov(X , Y)».

— **Covarianza.** La covarianza se define mediante esta ecuación:

$$\text{Cov}(X, Y) = E [(X - E[X]) (Y - E[Y])] \quad (6)$$

Resulta que esta ecuación implica la siguiente, que suele ser la más usada en la práctica:

$$\text{Cov}(X, Y) = E [X Y] - E[X] E[Y] \quad (7)$$

La covarianza es una relación *simétrica*, de forma que $\text{Cov}(X, Y) = \text{Cov}(Y, X)$.

Habiendo visto la covarianza, podemos comprender la importancia de la correlación. Esta nos brinda una forma más cuantitativa de medir la relación conjunta entre dos variables aleatorias. Por supuesto, la covarianza de dos variables ya es una cantidad, pero no tiene un intervalo de variación determinado: no siempre toma los mismos valores, sino que los valores de la covarianza dependen de los valores que tomen las variables que comparamos. A diferencia de ello, el coeficiente de correlación sí tiene un intervalo

determinado: solamente puede tomar valores entre -1 y 1. Se dice entonces que la correlación está *normalizada*, pero no la covarianza.

Que la correlación esté normalizada nos permite interpretarla más fácilmente. Las variables con correlación 0 no muestran ninguna relación entre sus valores: a valores más altos de una variable, la otra puede tomar iguales, más altos, o más bajos. Las variables con correlación 1 muestran *correlación positiva perfecta*: a más altos valores de una, más altos valores de la otra también, y a más bajos valores de una, más bajos valores de la otra también. Las variables con correlación -1 muestran correlación negativa perfecta: a más altos valores de una, más bajos los valores de otra, y viceversa. Así, si el valor de la correlación entre las variables se acerca a 1, van a estar cerca de estar perfectamente correlacionadas (positivamente); si se acerca más bien a cero, van a estar cerca de no estar en absoluto correlacionadas, y si se acerca a -1, van a estar cerca de tener una correlación negativa perfecta. Entonces, el hecho de que la correlación siempre tome valores en el mismo intervalo (de -1 a 1) nos permite comparar distintos pares de variables respecto a qué tanto están correlacionadas entre sí.

Ahora vamos a definir la correlación, que se suele conocer como el *coeficiente de correlación de Pearson*.⁶

- **Correlación de Pearson.** Donde X , Y son dos variables aleatorias, escribimos el coeficiente de correlación de Pearson como $\rho(X, Y)$, definido por:

$$\frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} \quad (8)$$

con $\text{Cov}(X, Y)$ la covarianza entre X e Y y σ_X , σ_Y las respectivas desviaciones estándar.


Como la covarianza, la correlación es simétrica: $\rho(X, Y) = \rho(Y, X)$.

Antes vimos que la correlación entre dos variables toma valores de -1 a +1. Si $\rho(X, Y) = -1$, se dice que las dos variables tienen una *anti-correlación*


⁶ Por motivos de simplicidad, la definición es para el coeficiente para poblaciones. También se puede definir uno para muestras, que involucra estimaciones tomadas de la muestra.

perfecta o una *correlación negativa perfecta*. Si tienen correlación 0, se dice que son *independientes*. Y si tienen correlación 1, están *perfectamente correlacionados*.


Podemos representar gráficamente a las relaciones de correlación positiva, negativa, y de falta de correlación entre dos variables. Primero, ponemos una variable como el eje horizontal, y como eje vertical tenemos a la otra variable. Nos queda un plano de esta forma:




Luego acomodamos los datos que encontramos como puntos en esta gráfica. Por ejemplo, si encontramos que en un dato X toma el valor 3 y Y toma el valor 2, ponemos un puntito exactamente en las coordenadas (2, 3). Seguimos así. Entonces, si las dos variables no presentan ninguna correlación, vamos a ver una «nube» de puntos que no se parecen a ninguna línea recta, como la siguiente:




Sin embargo, cuando las dos variables aleatorias presentan correlación positiva, la gráfica se va a parecer a esta:




Nota como los valores de las dos variables correlacionadas se acercan a una línea recta, que ponemos en rojo. Si todos los valores estuvieran en la misma recta, la correlación sería perfecta, pues en cada circunstancia ambas variables darían exactamente el mismo valor.



Cuando las variables tienen una correlación negativa, los valores altos de una se van a corresponder con los valores bajos de la otra, y viceversa.



Como con la correlación positiva, podemos notar que la correlación negativa se aproxima a una línea, solamente que en este caso es una línea descendente. De nuevo, si los puntos que representan a los datos que conocemos estuvieran todos sobre la línea roja, tendríamos una correlación negativa perfecta.



Este concepto de correlación se llama *lineal* porque entiende a la correlación perfecta (ya sea negativa o positiva) como una línea, tal como se ve en las gráficas anteriores. Sin embargo, no todas las variables van a tener una correlación lineal: quizá sus valores describen una curva en el plano. En ese caso, no es que no tengan correlación, es que su correlación es *no lineal*. Este concepto es más complicado y necesitaríamos más espacio para revisarlo, pero es bueno tener en mente que la falta de correlación lineal no significa que no haya algún tipo de correlación.

Correlación no implica causalidad


Ahora podemos ver una de las ideas más importantes para comprender a la inferencia causal: *Correlación no implica causalidad*. Es decir, dos eventos pueden ocurrir conjuntamente, incluso muchas veces, sin que ninguno cause al otro. *Que dos cosas sucedan conjuntamente no significa que una haya provocado a la otra*. Por supuesto, en algunos casos sí sucede que un evento causa al otro, pero no necesariamente en todos.

Entre los eventos correlacionados que no exhiben relaciones causales, podemos hacer la siguiente división:

- Ninguno causa al otro: la correlación es una coincidencia.
- Ninguno causa al otro, pero sí hay otras relaciones causales más complicadas.

Para entender los casos del segundo tipo, en los que la correlación no es una mera coincidencia, será útil considerar algunos diagramas.

Vamos a usar dobles flechas azules para representar correlaciones, y una flecha ondulada naranja para representar causación (de manera que la flecha vaya de la causa al efecto: « $C \rightsquigarrow A$ » significará que C causa a A). Por ejemplo, en el caso 1 de abajo, A y B están correlacionados, pero uno no causa al otro. Su correlación se debe a que ambos tienen una causa común, que los causa simultáneamente.



Inferir que *A* causa *B* (o viceversa) de la mera información de que ambos tipos de eventos están correlacionados, es cometer una *falacia*: se dice que se infiere causalidad de correlación. Pero, como hemos visto, la mera correlación no implica a la causalidad. En un tema relacionado con esto, encontramos a una falacia similar, la conocida como «*post hoc, ergo propter hoc*»: «después de esto, por lo tanto, debido a esto». En esta falacia, se infiere causalidad a partir de sucesión temporal. En ambos casos, se infiere una relación causal a partir de la cercanía de los eventos en el tiempo, lo cual es incorrecto.

Condiciones necesarias para la causalidad

Hemos visto que la correlación no implica a la causalidad. Entonces, la causalidad debe poseer otras características. ¿Cuáles son estas? De hecho, esta es una cuestión fuertemente debatida en la filosofía contemporánea (Schaffer 2016), así como en otras áreas que tratan con la inferencia causal.

Vamos a empezar con tres criterios cuya historia llega al menos hasta Hume (en sus famosos libros *Tratado de la Naturaleza Humana e Investigación sobre el conocimiento humano*). No sugiero estos como suficientes para caracterizar a la causalidad, sino como una propuesta inicial para entender qué se requiere para la causalidad. En lo que sigue, cuando hable de «dos eventos», pretendo que lo mismo valga para pluralidades o series de eventos, ya sea fungiendo como causas o como efectos.

Criterio de precedencia temporal. Un evento A causa a un evento B solamente si A ocurre antes que B .

Este criterio manifiesta la suposición de que no existe lo que se conoce como *causalidad retroactiva*: cuando la causa viene *después* del efecto. Todas las relaciones causales que conocemos obedecen el criterio de precedencia temporal: los efectos *siguen* a la causa.

Criterio de contigüidad espacial. Un evento A causa a un evento B solamente si A ocurre en la cercanía de B .

Este criterio manifiesta la suposición de que las relaciones causales son *locales*: que se dan entre eventos cercanos entre sí. Por supuesto, un evento puede afectar a otro que esté lejos de este, pero para ello tiene que haber una *vía causal* (sección 2.5.1).⁷

Criterio de conjunción constante. Un evento A causa a uno B solamente si los eventos del tipo de A y los del tipo de B están en conjunción constante, es decir, si cada vez que observamos uno, observamos al otro.

En la filosofía de Hume, este criterio era la base fundamental para las inferencias causales, que Hume creía que se basaban en la mera costumbre, producida por las observaciones repetidas de los fenómenos en conjunción. En términos más contemporáneos, pondríamos este criterio como la idea de que *la causalidad implica correlación* (pero no viceversa).

Alguien podría dudar de si todo caso de causalidad de hecho requiere a la correlación. Como hemos visto, la definición más exacta y extendida de correlación es el coeficiente de Pearson. Este nos da la covarianza entre dos variables aleatorias, normalizada por sus respectivas desviaciones estándar. Cada una de las circunstancias posibles en las que la variable toma un valor es un evento, así que son estos los que pueden entrar en relaciones causales. Sin embargo, la correlación es una relación entre variables aleatorias, es decir, entre *tipos* de eventos. Entonces, para que la causalidad implique la correlación, tendría que suceder que, siempre que un evento causa a otro,

⁷ Existe debate sobre si algunos resultados de la física —específicamente el teorema de Bell— ponen en duda la idea de la localidad o la precedencia temporal (Bell 1987). Esto nos lleva a temas que no podemos discutir aquí.

los demás posibles valores de las variables correspondientes tiendan a variar conjuntamente (suponiendo que las condiciones de fondo se mantengan iguales). ¿Sucedee esto en todos los casos? Es una pregunta interesante para reflexionar unos momentos, pero no intentaremos dar una respuesta definitiva aquí.

Regresando a las condiciones necesarias de la causalidad, podemos pasar a un criterio más con- temporáneo, que ha sido discutido desde el siglo pasado. Algunas teorías de la causalidad (influidas por la filosofía de David Lewis) incluso reducen la causalidad al siguiente criterio (o a variaciones de este), pero esa propuesta es muy controvertida. Sin embargo, muchos teóricos consideran plausible la idea de que la causalidad requiere de la dependencia contrafáctica, en el sentido siguiente.

Criterio de dependencia contrafáctica. Un evento *A* causa a uno *B* solamente si sucede que: si no hubiera sucedido *A*, no hubiera sucedido *B*. Es decir: si quitáramos a *A* de la circunstancia, también quitaríamos a *B*.

En la base de este criterio está la idea de que la causalidad es «robusta» o «estable», en el sentido de que, si es que se da, también se hubiera dado en circunstancias parecidas. La idea es que el efecto dependa contrafácticamente de la causa en el sentido en que, sin la causa, no tendríamos el efecto. Esta es una forma de comprender la noción de que la causa *genera* o *produce* al efecto. Si estamos suponiendo que el evento solamente tiene una causa, es razonable suponer entonces que se cumpla este criterio se requiere (pero no basta) para afirmar razonablemente la hipótesis causal de que *A* causó a *B*.⁸

Vemos que este criterio involucra considerar circunstancias *meramente hipotéticas* o, como también se dice, *contrafácticas*: circunstancias que no ocurrieron, pero que podrían haber ocurrido. Por esta razón, encontrar qué depende contrafácticamente de qué, puede resultar un problema complejo. En las ciencias empíricas, usualmente se busca reproducir diferentes condiciones, de forma que se puedan aproximar diferentes circunstancias hipotéticas.

⁸ Estoy dejando de lado sutilezas conceptuales como los casos de preempción. Aunque filosóficamente muy importantes, no es el lugar para discutirlos con el detalle requerido.

Causalidad: Vías y manipulabilidad

Vías causales

Las ciencias contemporáneas, particularmente las ciencias médicas y de la salud, además de algunas ciencias sociales, se enfocan en lograr entender las *vías causales*. Estas son los *canales* o *vías* mediante los cuales ciertos eventos llegan a causar efectos que parecen estar desconectados en el tiempo y el espacio.

Consideremos el ejemplo de la afirmación: *fumar causa cáncer*. Esta es una hipótesis causal bien fundamentada en la evidencia, y se conocen las vías causales mediante las que el fumar lleva al cáncer. Así, fumar produce la absorción de compuestos (como los hidrocarburos aromáticos policíclicos) que son activados metabólicamente al ser catalizados por enzimas citocromo P450. Esta activación permite que los compuestos puedan formar enlaces covalentes con el ADN. A su vez, estos forman aductos de ADN. Los aductos de ADN pueden causar errores en el proceso de replicación de las células, los cuales resultan en mutaciones (como las transversiones G→T). Estas mutaciones causan alteraciones en los controles del crecimiento celular. La multiplicación descontrolada de células anómalas causa cáncer. Esta es la vía mediante el cual un tipo de eventos —en donde se fuma un cigarrillo— lleva hacia la aparición del cáncer.

Para cada uno de los componentes de una vía causal, podemos utilizar los métodos de Mill que revisaremos abajo.

Manipulabilidad

Otro criterio que se recientemente se utiliza bastante para encontrar relaciones causales es el de *manipulabilidad*.

Consideremos dos criterios que revisamos antes (§2.4): el de precedencia temporal y el contrafáctico: *A* ocurre antes que *B* y, si *A* causa *B*, eso significa que si no sucediera *A*, no sucedería *B*, pero si sí sucede *A*, sucederá *B*. Esta es una condición hipotética, es decir, una condición que nos habla de lo que sucedería en otras circunstancias, sin requerir que sean las circunstan-

cias presentas. Podríamos cuestionar esta condición: ¿Cómo podemos saber qué ocurriría en situaciones puramente hipotéticas?

Una manera de tratar con esta cuestión en la práctica es mediante el concepto de *manipulabilidad* o *intervención*.

La idea detrás de esto es la siguiente. Como vimos antes, una correlación entre las variables *A* y *B* puede ser meramente accidental cuando no haya una relación causal entre las dos variables (o, mejor dicho, entre los eventos que representan). También puede ser que haya alguna otra variable u otras variables, en cuyo caso hablamos de una *tercera causa*.

Si la correlación es meramente accidental o hay una tercera causa, entonces podemos modificar una de las variables *A* o *B* sin que esto implique una modificación en la otra. A esto se le llama intervenir en la variable. Si la correlación no manifiesta una relación causal entre *A* y *B*, una intervención en una de ellas no implicará una modificación en la otra. Así, si nos damos cuenta de que, al intervenir en una variable, la otra variable correlacionada se modifica de manera correspondiente, tenemos evidencia de que la primera variable es un factor causal de la segunda.

Una manera de intervenir es buscar los factores con los que *A* está correlacionado y tratar de «bloquearlos» o «suspenderlos» —ya sea en un experimento controlado, o en el cálculo estadístico; hacemos esto con todos exceptuando a uno, para probar si este es una causa de *A*. Además, recordemos que la variable que sea la causa debe anteceder en el tiempo al efecto.

Por ejemplo, supongamos que queremos encontrar si el tomar una medicina causa que los pacientes mejoren en cierta condición. Si solamente medimos qué tanto mejoran los pacientes al haber tomado la medicina, esto no necesariamente nos habla de ella: los pacientes podrían haber mejorado por otras razones. Sin embargo, podríamos bloquear los demás factores: considerar pacientes que estén en condiciones parecidas, y considerar la mejora en pacientes a los que no se les suministre la medicina (por ejemplo, solo se les da un *placebo*: un dispositivo que se asemeja al medicamento original, pero sin principio activo). Si encontramos que hay una mejora en los pacientes a los que se les da la medicina, pero no en el grupo en el que no se suministra la medicina (que se conoce como *grupo control*), tenemos evidencia de que existe un vínculo causal de la medicina sobre la mejora: es decir, evidencia de que la medicina causó la mejora.

Esta se considera una buena manera de obtener evidencia sobre vínculos causales porque la variable que podría ser el efecto —la que representa a la mejora en los pacientes— se aísla de otras posibles causas —al considerarse personas en situaciones parecidas y al usarse un grupo control— y se mide si modificar la variable que podría ser una causa —la que representa el tomar la medicina— de hecho sirve para modificar a la otra variable. Si esto pasa, se considera que hay una relación causal: manipular una variable lleva a manipular a la otra, cuando se han bloqueado los otros posibles *factores confundentes*.

Por supuesto, en muchos casos no es factible utilizar estos estándares experimentales, por cuestiones éticas, de posibilidad tecnológica, u otras. Para lidiar con esos casos, existen técnicas estadísticas que permiten aislar las variables de interés, de tal manera que sea un procedimiento análogo al que hemos descrito.

Finalmente, el método mencionado antes para aislar posibles factores confundentes cae dentro de los diferentes métodos de Mill, que ahora vamos a presentar.

Los métodos de Mill para aislar factores causales

En su libro de 1843, *Un Sistema de Lógica* (en el octavo capítulo del tercer libro), John Stuart Mill propuso cinco métodos para hacer inferencias causales. Aunque Mill no lo puso así, hay que recordar que estos métodos son probabilísticos y que requieren de una cláusula *ceteris paribus*. Lo primero significa que no estamos frente a métodos deductivos: que puede suceder que las premisas sean verdaderas, pero que la conclusión sea falsa. Sobre lo segundo, una cláusula *ceteris paribus* significa que la inferencia se hace *dando por supuesto que se preserva una igualdad de condiciones*. La idea es que se dejan las condiciones fijas, para poder aislar solamente la variable que nos interesa modificar y, con ello, estudiar los efectos de hacerlo. En esencia, los métodos de Mill precisamente buscan eso: *aislar factores para confirmar una hipótesis sobre cuáles están involucrados en relaciones causales*.

En los cinco métodos, comparamos circunstancias en las que se presentan dos tipos de factores: los que pueden resultar ser causas, y los que pensamos que pueden ser los efectos correspondientes; solo que no sabemos cuál

es cuál. Es decir, tenemos dos tipos de factores, y nuestra hipótesis es que hay una relación causal entre esos dos tipos (o algunos miembros de esos dos tipos). Vamos a seguir la convención de utilizar variables mayúsculas de las primeras letras del alfabeto (como $A, B, C, \dots$) para el primer tipo, y variables minúsculas de las últimas letras del alfabeto (como $x, y, z, \dots$) para el segundo. Vamos a usar tres o cuatro de cada una de estos tipos de variables, pero entenderemos que el número puede ser distinto. Otra convención es que en algunos casos mencionaremos solamente dos circunstancias, pero entenderemos que podemos comparar más circunstancias entre sí.

El método de concordancia

Para este método, comparamos dos circunstancias, las cuales contienen dos conjuntos distintos de factores, excepto por uno. Es decir, tenemos un par de circunstancias así:

Circunstancia 1: A, B, C

Circunstancia 2: A, D, E

Y en ellas, encontramos los siguientes factores:

Circunstancia 1: x, y, z

Circunstancia 2: x, u, w

Al comparar ambas circunstancias, el primer método de Mill nos lleva a inferir que es probable que A tenga una relación causal con x , ya sea como causa o como efecto. Esto sucede porque vemos que son los únicos dos factores que se repiten, que concuerdan en ambas circunstancias. Mill lo resumía así (p. 369):

Si dos o más fenómenos objeto de la investigación tienen solamente una circunstancia común, la circunstancia en la cual todos los casos concuerdan es la causa (o el efecto) del fenómeno.

Vamos a usar la manera usual de esquematizar los métodos de Mill, como inferencias probabilísticas donde la descripción de las circunstancias nos da las premisas, y la conclusión es una hipótesis causal.

Método de la concordancia

Los factores *A, B, C* ocurren junto con los factores *x, y, z*.

Los factores *A, D, E* ocurren junto con los factores *x, u, w*.

Probablemente, *A* tiene una relación causal con *x*.

El método de diferencia

En el segundo método, comparamos circunstancias distintas donde los factores en los que nos enfocamos no se repiten, como en el método anterior, sino que faltan. Si encontramos que, cuando un factor de un tipo falta, también falta un factor de otro tipo, esto nos da una base para inferir que, probablemente, esos dos factores están relacionados causalmente. Mill lo sintetizaba así (p. 370):

Si un caso en el cual el fenómeno se presenta y un caso en que no se presenta tienen todas las circunstancias comunes, fuera de una sola, presentándose esta solamente en el primer caso, la circunstancia única en la cual difieren los dos casos es el efecto, o la causa, o parte indispensable de la causa, del fenómeno.

Este es el esquema del segundo método:

Método de la diferencia

Los factores *A, B, C* ocurren junto con los factores *x, y, z*.

Los factores *B, C* ocurren junto con los factores *y, z*.

Probablemente, *A* tiene una relación causal con *x*.

El método conjunto de concordancia y diferencia

En el tercer método combinamos los dos anteriores.

Si dos casos o más en los cuales se efectúa el fenómeno tienen una sola circunstancia común, mientras que dos casos o más en los cuales no se efectúa no tienen más de común que la ausencia de esta circunstancia, la circunstancia por la cual únicamente difieren los dos grupos de casos es el efecto, o la causa, o una parte necesaria de la causa del fenómeno.

Este es el esquema del segundo método:

Método conjunto de concordancia y diferencia

Los factores *A, B, C* ocurren junto con los factores *x, y, z*.

Los factores *B, C* ocurren junto con los factores *y, z*.

Los factores *A, D, E* ocurren junto con los factores *x, u, w*.

Probablemente, *A* tiene una relación causal con *x*.

El método de residuos

Este método sirve cuando tenemos conocimiento ya establecido de algunas relaciones causales. Cuando esto sucede, eliminamos los factores de los cuales ya sabemos que tienen relaciones causales, y los restantes —el «residuo»— deben ser los que tengan relaciones causales con los otros factores restantes. Así lo explicaba Mill (p. 378):

Separemos de un fenómeno la parte que se sabe, por inducciones anteriores, ser el efecto de ciertos antecedentes, y el residuo del fenómeno es el efecto de los antecedentes restantes.

Este es el esquema del tercer método:

Método de residuos

Los factores A , B , C ocurren junto con los factores x , y , z .

Se sabe que B causa a y .

Se sabe que C causa a z .

Probablemente, A tiene una relación causal con x .

El método de variaciones concomitantes

En los métodos anteriores podíamos eliminar algunos factores para notar qué permanece o qué falta. Este método lo usamos cuando no eliminamos algunos factores para tratar de aislar uno específico. Mill introdujo así al concepto (p. 380):

Aunque sea imposible excluir completamente un antecedente, podemos estar en situación, o la Naturaleza por nosotros, de modificarle de alguna manera. Por modificación es preciso entender un cambio, que no llega hasta su supresión total.

Si entendemos estas modificaciones como manipulaciones o intervenciones, este método se relaciona con el concepto de manipulabilidad que revisamos antes (sección 2.5.2). Mill lo sintetizó así (p. 382):

Un fenómeno varía de cierta manera, siempre que otro varía de la misma manera, es, o una causa o un efecto del fenómeno, o está ligado a él por algún hecho de causación.

Vamos a ver el esquema del quinto y último método de Mill. Para ello, vamos a seguir la convención de utilizar el símbolo « $\pm$ » para referirnos a una modificación en el evento, de forma que (por ejemplo) « $A\pm$ » se refiere a una modificación en el evento A . (Podría ser que una variable se hace más intensa, o menos intensa, u otro tipo de modificación.) Así, tendríamos el último esquema:

Método de residuos

Los factores A, B, C ocurren junto con los factores x, y, z .

Los factores $A\pm, B, C$ ocurren junto con los factores $x\pm, y, z$.

Probablemente, A tiene una relación causal con x .

Podemos ver que ninguno de los cinco métodos nos permite calcular una probabilidad precisa para la hipótesis causal que inferimos como conclusión en cada método. Así, cada uno de los métodos es un esquema, una guía general y cualitativa para el pensamiento crítico. Para tener estimaciones cuantitativas precisas como las que se usan en las ciencias experimentales, se requieren herramientas más avanzadas de la estadística moderna.

Conclusiones

Hemos revisado algunos conceptos esenciales de la teoría de la probabilidad y la estadística, así como algunos aspectos de la filosofía de la causalidad, asociados con las filosofías mecanicistas y manipulacionistas de la causalidad. Con esto, espero haber aclarado el contenido de la tesis de que causalidad no implica correlación. Finalmente, también hemos revisado los métodos de Mill, que nos exponen formas cualitativas de razonar causalmente. Aunque estos métodos son probabilísticos, en lugar de deductivos, me parece razonable tomarlos como una buena guía metodológica en nuestros razonamientos causales.

Bibliografía

Bell, John S. (1987).

Speakable and Unspeakable in Quantum Mechanics. Cambridge University Press.

Hume, David. (2005).

Tratado de la Naturaleza Humana. Traducción de Félix Duque. Tecnos.

_____. **(1980).**

Investigación sobre el conocimiento humano. Traducción, prólogo y notas de Jaime de Salas Ortueta. Alianza Editorial.

Mill, Stuart. (1843).

Sistema de Lógica Inductiva y Deductiva. Traducción de Eduardo Ovejero. Madrid, 1917. Consultado en: <https://bvpb.mcu.es/es/consulta/registro.do?id=409180>, noviembre de 2020.

Rincón, Luis. (2014).

Introducción a la Probabilidad. Facultad de Ciencias, UNAM.

Schaffer, Jonathan. (2016).

«The Metaphysics of Causation». *The Stanford Encyclopedia of Philosophy* (Fall 2016 Edition), Edward Zalta (ed.), <https://plato.stanford.edu/archives/fall2016/entries/causation-metaphysics/>.

Stroud, Barry. (1986).

Hume. Traducción de Antonio Ziri6n. UNAM.